Atividades Tira questão ‘Trabalho’

Ademar Araujo Teisen 23182969-2 / Roberto Yanez Sanz 23079491-2

Esoft A7°S

Aula 000

Atividade Traga 1 exemplo real (app mobile, web ou desktop) de aplicação de IA em um software. Software + problema (1 frase) Funcionalidade de IA (o que faz) + entrada/saída Técnica provável (ex.: classificação, recomendação, LLM/RAG, visão) Métrica de sucesso (como medir)

Exemplo: Nubank (Detecção de Fraudes)

- **Software + Problema: Aplicativo de serviços financeiros que precisa identificar transações fraudulentas em tempo real antes que o prejuízo financeiro ocorra ao cliente ou à instituição.**
- **Funcionalidade de IA: O sistema analisa o comportamento de compra do usuário e bloqueia automaticamente transações suspeitas.**
    - **Entrada: Dados da transação atual (valor, local, horário, categoria), histórico de compras do usuário e dados do dispositivo.**
    - **Saída: Um score de risco (0 a 100) que define se a transação deve ser aprovada, bloqueada ou enviada para verificação em duas etapas.**
- **Técnica Provável: Classificação (Aprendizado de Máquina Supervisionado). Utiliza modelos como *Random Forest* ou *XGBoost* treinados com milhões de exemplos de transações passadas (rotuladas como "legítimas" ou "fraudes").**
- **Métrica de Sucesso: Taxa de Falsos Positivos (transações legítimas bloqueadas por engano) e Recall (porcentagem de fraudes reais que o sistema conseguiu capturar com sucesso).**

Aula 1

1. Manipulação de Dados com Pandas

O **Pandas** é como um Excel turbinado via código. É essencial para limpar dados antes de enviá-los para um banco ou modelo.

import pandas as pd

```
# Criando um mini DataFrame (como se fosse uma tabela do seu BD)

dados = {

    'Projeto': ['IntalenTIVagas', 'gestaoDindin', 'Portfolio'],

    'Horas': [120, 45, 30]

}


df = pd.DataFrame(dados)


# Criando uma nova coluna calculada

df['Dias_Estimados'] = df['Horas'] / 8


# Filtrando projetos com mais de 40 horas

mais_longos = df[df['Horas'] > 40]

print(mais_longos)
```

2. Machine Learning com scikit-learn

O **scikit-learn** serve para criar modelos preditivos. Aqui, um exemplo clássico de "Classificação".

```
from sklearn.linear_model import LogisticRegression

import numpy as np


# Dados fictícios: [Horas_Estudadas, Projetos_Entregues]

X = np.array([[10, 1], [50, 5], [5, 0], [100, 10]])

# Resultado: 0 (Junior), 1 (Pleno/Senior)

y = np.array([0, 1, 0, 1])


# Criando e treinando o modelo
```

```
modelo = LogisticRegression()

modelo.fit(X, y)


# Prevendo o nível de alguém que estudou 80 horas e entregou 7 projetos

previsao = modelo.predict([[80, 7]])

print(f"Predição de Senioridade (0=JR, 1=PL/SR): {previsao[0]}")
```

3. Visualização com Matplotlib

O **Matplotlib** transforma números em gráficos, facilitando a análise de tendências.

```
import matplotlib.pyplot as plt


# Dados de evolução de estudos

meses = ['Jan', 'Fev', 'Mar', 'Abr']

commits = [20, 45, 30, 85]


plt.plot(meses, commits, marker='o', color='green')

plt.title('Evolução de Commits no GitHub')

plt.xlabel('Meses')

plt.ylabel('Quantidade de Commits')

plt.grid(True)

plt.show() # Abre uma janela com o gráfico
```

1) Importância da Preparação de Dados
2) Valores Ausentes
3) Normalização vs Padronização

Exercícios de Preparação de Dados para Machine Learning

1. Conceitual – Importância da Preparação

Explique por que a etapa de preparação de dados pode impactar mais o desempenho de um modelo do que a escolha do algoritmo de Machine Learning.

2. Valores Ausentes

Considere um dataset com 10.000 registros onde 25% das entradas da variável idade estão ausentes.

- a) Quais são as possíveis estratégias para tratar esses valores?
- b) Em quais situações remover registros é inadequado?

3. Normalização vs Padronização

Explique a diferença entre:

- Normalização (Min-Max)
- Padronização (Z-score) Em quais tipos de algoritmos cada uma é mais recomendada? Justifique.

4. Dados Categóricos

Você possui a variável: clima = {sol, chuva, nublado}

- a) Como transformar essa variável para uso em um modelo de Machine Learning?
- b) Qual problema pode ocorrer se utilizarmos apenas codificação numérica simples (0,1,2)?

5. Overfitting e Separação de Dados

Explique por que dividimos o dataset em:

- Treino
- Validação
- Teste O que acontece se utilizarmos o conjunto de teste durante o treinamento?

6. Balanceamento de Classes

Considere um problema onde:

- 95% das amostras pertencem à classe A

- 5% pertencem à classe B
- a) Qual problema pode ocorrer?
- b) Cite duas técnicas para tratar esse desbalanceamento.

7. Detecção de Outliers

Explique:

- a) O que são outliers
- b) Quando removê-los pode prejudicar o modelo
- c) Um método estatístico para detectá-los

8. Feature Engineering

Dado o dataset: data_nascimento Explique por que criar a variável idade pode ser melhor do que usar diretamente a data de nascimento.

9. Pipeline de Pré-processamento

Descreva um pipeline completo de preparação para um dataset que contém:

- Valores ausentes
- Dados categóricos
- Variáveis com escalas diferentes
- Classes desbalanceadas

10. Estudo de Caso Aplicado

Você recebeu um dataset para prever aprovação em crédito bancário. Variáveis:

- renda_mensal
- idade
- estado_civil
- número_de_dependentes
- histórico_de_inadimplência

Descreva todas as etapas de preparação antes de treinar o modelo. Seja específico.

1. Conceitual – Importância da Preparação

A preparação de dados é crucial porque algoritmos de Machine Learning são funções matemáticas que dependem da qualidade dos dados de entrada (conceito de *Garbage In, Garbage Out*). Dados mal preparados (com ruído ou escalas discrepantes) podem levar o modelo a aprender padrões inexistentes ou a ignorar variáveis importantes, independentemente da complexidade do algoritmo escolhido.

2. Valores Ausentes

- **a) Estratégias: * Imputação Estatística:** Substituir pela média, mediana ou moda.
    - **Imputação Preditiva:** Usar outros algoritmos para prever o valor ausente.
    - **Preenchimento Constante:** Atribuir um valor fixo ou uma flag (ex: "Desconhecido").
- **b) Quando não remover:** Remover registros é inadequado quando o dataset é pequeno (perda de informação crítica) ou quando a ausência do dado não é aleatória e carrega um significado intrínseco ao negócio.

3. Normalização vs Padronização

- **Normalização (Min-Max):** Redimensiona os dados para um intervalo fixo (geralmente [0, 1]). Recomendada para algoritmos que não assumem distribuição específica, como **KNN** e **Redes Neurais**.
- **Padronização (Z-score):** Transforma os dados para terem média 0 e desvio padrão 1. Recomendada para algoritmos que assumem distribuição gaussiana ou são sensíveis a outliers, como **SVM**, **Regressão Linear** e **Logística**.

4. Dados Categóricos

- **a) Transformação:** O uso de **One-Hot Encoding** é o mais indicado para variáveis sem ordem (nominais).
- **b) Problema da codificação simples:** Usar (0, 1, 2) pode fazer o modelo interpretar erroneamente que existe uma hierarquia ou ordem de grandeza entre as categorias (ex: "nublado" é maior que "sol"), o que prejudica a análise.

5. Overfitting e Separação de Dados

- **Divisão: * Treino:** Onde o modelo aprende.
    - **Validação:** Onde ajustamos os hiperparâmetros.
    - **Teste:** Avaliação final com dados nunca vistos (mundo real).

- **Uso do teste no treino:** Isso causa o **vazamento de dados (data leakage)**. O modelo "decoreba" as respostas, resultando em métricas excelentes no papel, mas falha total na produção por falta de capacidade de generalização.

6. Balanceamento de Classes

- **a) Problema:** O modelo ficará enviesado para a classe majoritária (A), atingindo alta acurácia simplesmente chutando "Classe A" em tudo, mas falhando miseravelmente em detectar a classe de interesse (B).

- **b) Técnicas: SMOTE** (oversampling da classe minoritária) ou **Undersampling** (reduzir a classe majoritária).

7. Detecção de Outliers

- **a) O que são:** Valores que fogem drasticamente do padrão da amostra.

- **b) Quando não remover:** Em casos onde o outlier é o evento de interesse (ex: detecção de fraude ou falha em equipamentos).

- **c) Método: IQR (Intervalo Interquartil)** ou **Z-score**.

8. Feature Engineering

A data_nascimento isolada não é interpretável por muitos modelos lineares. A variável idade (numérica) fornece uma relação direta de grandeza e correlação com comportamentos (ex: risco de crédito aumenta/diminui conforme a idade), facilitando o aprendizado do padrão.

9. Pipeline de Pré-processamento

1. **Imputação:** Tratar nulos.

2. **Codificação:** Transformar categóricos (One-Hot).

3. **Escalonamento:** Padronizar/Normalizar.

4. **Balanceamento:** Aplicar SMOTE se necessário.

5. **Engenharia:** Criar novas variáveis a partir das existentes.

10. Estudo de Caso (Crédito Bancário)

1. **Limpeza:** Tratar nulos em número_de_dependentes (imputar 0).

2. **Conversão:** estado_civil e histórico_de_inadimplência (categóricos para One-Hot).

3. **Normalização:** renda_mensal e idade (possuem escalas muito diferentes).

4. **Detecção de Outliers:** Verificar rendas mensais irreais que podem distorcer o modelo.

5. **Balanceamento:** Garantir que o modelo veja exemplos suficientes de bons e maus pagadores (comum estarem desbalanceados).

Aula 2

Git Hub:https://github.com/ADM-448/Trabalhos-Materia-IA-Munifaula

Aula 4

```
import pandas as pd


# 1. Montagem do Conjunto de Dados (Img 1)

data = {

   'Idade': ['infantil', 'infantil', 'infantil', 'infantil', 'adolescente', 'adolescente', 'adolescente', 'adolescente', 'adolescente', 'adulto', 'adulto', 'adulto', 'adulto', 'adulto', 'adulto'],

   'Diagnostico': ['miopia', 'miopia', 'hipermetropia', 'hipermetropia', 'miopia', 'miopia', 'miopia', 'hipermetropia', 'hipermetropia', 'miopia', 'miopia', 'miopia', 'hipermetropia', 'hipermetropia', 'hipermetropia'],

   'Astigmatismo': ['nao', 'sim', 'nao', 'sim', 'nao', 'sim', 'nao', 'nao', 'sim', 'nao', 'sim', 'sim', 'nao', 'sim', 'nao'],

   'Taxa_lacrimal': ['reduzida', 'normal', 'normal', 'normal', 'reduzida', 'reduzida', 'normal', 'reduzida', 'normal', 'normal', 'normal', 'normal', 'reduzida', 'normal', 'normal'],

   'Classe': ['nenhuma', 'gelatinosa', 'gelatinosa', 'dura', 'gelatinosa', 'nenhuma', 'dura', 'gelatinosa', 'dura', 'gelatinosa', 'dura', 'gelatinosa', 'nenhuma', 'dura', 'gelatinosa']

}



df = pd.DataFrame(data)



def naive_bayes_laplace(df, query, alpha=1):

   classes = df['Classe'].unique()

   total_samples = len(df)

   results = {}
```

```
    # Probabilidade a priori: P(Classe) suavizada
    # |V_classe| = número de classes (3: nenhuma, dura, gelatinosa)
    v_classe = len(classes)

    for c in classes:
        df_c = df[df['Classe'] == c]
        p_classe = (len(df_c) + alpha) / (total_samples + alpha * v_classe)

        # Probabilidade condicional: P(Atributo | Classe)
        p_condicional = 1.0
        for col, val in query.items():
            count_attr_c = len(df_c[df_c[col] == val])
            v_attr = len(df[col].unique()) # Número de categorias do atributo

            prob = (count_attr_c + alpha) / (len(df_c) + alpha * v_attr)
            p_condicional *= prob

        results[c] = p_classe * p_condicional

    # Normalização
    soma_probas = sum(results.values())
    normalized_results = {c: (p / soma_probas) for c, p in results.items()}

    return normalized_results

# 2. Resolução do Exercício (Img 2)
# Paciente: Idade: infantil | Diagnóstico: hipermetropia | Astigmatismo: não | Taxa: reduzida
```

```
paciente = {
    'Idade': 'infantil',
    'Diagnostico': 'hipermetropia',
    'Astigmatismo': 'nao',
    'Taxa_lacrimal': 'reduzida'
}

previsao = naive_bayes_laplace(df, paciente)

print("--- Probabilidades Normalizadas ---")
for classe, prob in previsao.items():
    print(f"{classe.capitalize()}: {prob:.2%}")
```

SAIDA:

```
--- Probabilidades Normalizadas ---
Nenhuma: 48.48%
Gelatinosa: 44.89%
Dura: 6.63%
```

Aula 9 - Ex p. 53

1 - FAÇA A TABLE

Tipo de lente: D + 1/3

Nenhum: 3/15 α ⇒ D 4/18

Dura: 4/15 ⇒ D 1/18

Gelatinosa: 8/15 ⇒ D 9/18

Idade / Tipo	N	D	G	α ⇒ D (+1/3)	N	D	G
Infantil	1/3	1/4	3/8		2/6	2/7	3/11
Adolescente	1/3	3/4	2/8		2/6	3/7	3/11
Adulto	1/3	1/4	4/8		2/6	2/7	5/11

Diagnóstico / Tipo	N	D	G	α ⇒ D (+1/2)	N	D	G
Miopia	2/3	2/4	4/8		3/5	3/6	5/10
hipermetropia	1/3	2/4	4/8		2/5	3/6	5/10

Astig / Tipo	N	D	G	α ⇒ D (+1/2)	N	D	G
Sim	1/3	3/4	3/8		2/5	4/6	4/10
NÃO	2/3	1/4	5/8		3/5	2/6	6/10

Taxa / Tipo	N	D	G	α ⇒ D (+1/2)	N	D	G
Normal	0/3	4/4	6/8		1/5	5/6	7/10
Reduzida	3/3	0/4	2/8		4/5	1/6	3/10

2 - Qual a Probabilidade?

G → D $\frac{3}{11} \cdot \frac{5}{10} \cdot \frac{5}{10} \cdot \frac{3}{10} \times \frac{9}{18} = 0{,}0122 / 0{,}0286 = 42{,}7\%$

D → D $\frac{2}{7} \cdot \frac{3}{6} \cdot \frac{2}{6} \cdot \frac{1}{6} \times 1/18 = 0{,}0022 / 0{,}0286 = 7{,}69\%$

N → D $\frac{2}{6} \cdot \frac{2}{5} \cdot \frac{3}{5} \cdot \frac{4}{5} \times 4/18 = 0{,}0142 / 0{,}0286 = 49{,}65\%$

$0{,}0122 + 0{,}0022 + 0{,}0142 = 0{,}0286$

Aula 6

Age	Spectacle prescription	Astigmatism	Tear production rate	Recommended lenses
young	myope	no	reduced	none
young	myope	no	normal	soft
young	myope	yes	reduced	none
~~young~~	~~myope~~	~~yes~~	~~normal~~	~~hard~~
young	hypermetrope	no	reduced	none
young	hypermetrope	no	normal	soft
young	hypermetrope	yes	reduced	none
young	hypermetrope	yes	normal	hard
pre-presbyopic	myope	no	reduced	none
pre-presbyopic	myope	no	normal	soft
pre-presbyopic	myope	yes	reduced	none
~~pre-presbyopic~~	~~myope~~	~~yes~~	~~normal~~	~~hard~~
pre-presbyopic	hypermetrope	no	reduced	none
pre-presbyopic	hypermetrope	no	normal	soft
pre-presbyopic	hypermetrope	yes	reduced	none
pre-presbyopic	hypermetrope	yes	normal	none
presbyopic	myope	no	reduced	none
presbyopic	myope	no	normal	none
presbyopic	myope	yes	reduced	none
~~presbyopic~~	~~myope~~	~~yes~~	~~normal~~	~~hard~~
presbyopic	hypermetrope	no	reduced	none
presbyopic	hypermetrope	no	normal	soft
presbyopic	hypermetrope	yes	reduced	none
presbyopic	hypermetrope	yes	normal	none

Lenses None:

1. Avaliação dos Atributos para *none*

Atributo: Age

- **young:** 5/8 são *none* (62,5%)
- **pre-presbyopic:** 5/8 são *none* (62,5%)
- **presbyopic:** 5/8 são *none* (62,5%)

Atributo: Spectacle Prescription

- **myope:** 7/12 são *none* (58,3%)
- **hypermetrope:** 8/12 são *none* (66,6%)

Atributo: Astigmatism

- **no:** 9/12 são *none* (**75%**)
- **yes:** 6/12 são *none* (50%)

Atributo: Tear production rate

- **reduced:** 12/12 são *none* (**100%**)
- **normal:** 3/12 são *none* (25%)

Após analisar as probabilidades, o próximo passo do PRISM é identificar qual atributo isola melhor a classe **"none"**. O objetivo aqui é encontrar a regra com maior precisão (acurácia).

Ao comparar os resultados, percebemos que o atributo **"Tear production rate"** com o valor **"reduced"** é o único que atinge **100% de aproveitamento**. Ou seja, em todas as 12 vezes que ele aparece na tabela, o resultado é invariavelmente "none".

Diferente do atributo "Astigmatism", que apesar de ter uma boa frequência (75%), ainda gera dúvidas, o "Tear production rate = reduced" nos dá uma certeza absoluta. Por isso, o algoritmo seleciona essa condição para ser a nossa primeira regra:

- **Regra Gerada:** Se a taxa de produção de lágrima for reduzida, então a lente recomendada é nenhuma.

Com essa regra definida, o algoritmo "limpa" a tabela, removendo esses 12 casos já resolvidos, e passa a focar apenas nos dados restantes (onde a produção de lágrima é normal) para buscar novas associações que expliquem os outros casos de "none".